

Identificação e Correção de Gargalos de Level Design via Aprendizizado por Reforço Profundo

Robert Ronald Calla Maguinha
Departamento de Informática, PUC-Rio
Rio de Janeiro, RJ, Brasil

Abstract

Este trabalho relata o andamento do desenvolvimento de um sistema de Inteligência Artificial voltado à identificação e correção automática de gargalos de *level design* em fases 2D baseadas em física. O ambiente de desenvolvimento é estruturado na engine Godot 4.7, com foco em mecânicas multiplayer. Diferentemente de abordagens tradicionais de navegação (*pathfinding*), o objetivo é treinar um agente capaz de analisar a topologia do mapa, identificar zonas de estrangulamento que prejudicam a fluidez do jogo e sugerir adaptações de conteúdo para corrigi-las. A arquitetura proposta combina a extração estruturada do ambiente em uma matriz 2D, o processamento espacial por meio de Redes Neurais Convolucionais (CNN) e um agente de Aprendizado por Reforço Profundo (DRL) inspirado em conceitos de *Curiosity-Driven Exploration* e de *Procedural Content Generation via Reinforcement Learning* (PCGRL). Apresentamos o estado atual do projeto – com a arquitetura geral validada – e discutimos os próximos passos: a modelagem matemática da função de recompensa, a definição formal do espaço de ações e a integração de dados entre a engine e o ambiente de treinamento.

Keywords

Level Design, Aprendizado por Reforço Profundo, Geração Procedural de Conteúdo, Curiosity-Driven Exploration, Godot Engine, Playtesting Automatizado

1 Introdução

O *level design* é um dos pilares da experiência de jogo, mas identificar manualmente pontos de fricção que prejudicam a fluidez de uma fase – os chamados *gargalos* – é um processo custoso e dependente de extensas sessões de playtesting humano. Este trabalho relata o progresso da pesquisa e desenvolvimento de uma aplicação de Inteligência Artificial para identificação e correção desses gargalos. O ambiente de desenvolvimento está sendo estruturado na engine Godot 4.7, com foco no processamento de fases 2D baseadas em física e mecânicas multiplayer.

O objetivo do projeto é ir além da simples navegação (*pathfinding*). A meta é treinar um agente de aprendizado de máquina capaz de (i) analisar a topologia do mapa, (ii) identificar zonas de estrangulamento que prejudicam a fluidez do jogo e (iii) aplicar técnicas de geração de conteúdo para sugerir adaptações no cenário. Em outras palavras, o agente não deve apenas percorrer o nível, mas aprender a apontar – e eventualmente corrigir – falhas estruturais de design.

As contribuições deste relatório de andamento são:

- uma arquitetura de representação de ambiente independente de renderização gráfica, baseada em matrizes 2D extraídas diretamente do *TileMap* e do *NavigationServer2D* do Godot;
- uma proposta de pipeline *CNN + DRL* para transformar essa representação em decisões de ação sobre o nível; e
- a definição do escopo dos próximos passos necessários para a formalização da função de recompensa e do espaço de ações do agente.

2 Trabalhos Relacionados

O uso de aprendizado por reforço para geração e avaliação de conteúdo de jogos vem se consolidando como uma alternativa aos métodos tradicionais de geração procedural baseados em regras ou busca. Khalifa et al. [2] propõem o PCGRL (*Procedural Content Generation via Reinforcement Learning*), no qual a geração de níveis é formulada como um problema sequencial de decisão: um agente edita o mapa tile a tile e recebe recompensas conforme métricas de qualidade do nível resultante. Essa formulação inspira diretamente a representação de estado e o espaço de ação discutidos na Seção 3 deste trabalho.

Na frente de *playtesting* automatizado, De Woillemont et al. [1] utilizam aprendizado por reforço para gerar agentes com estilos de jogo semelhantes aos humanos, permitindo testar um jogo sob perfis de comportamento variados sem depender de testadores humanos para cada iteração. Sestini et al. [3] avançam essa linha propondo trajetórias proximais condicionadas por curiosidade (*curiosity-conditioned proximal trajectories*) para validação automatizada de *gameplay*, combinando exploração guiada por curiosidade com métodos de otimização de política por região de confiança.

O presente projeto se posiciona na interseção dessas duas linhas: assim como o PCGRL, utiliza uma representação matricial do nível como estado de um processo de decisão de Markov; e, assim como os trabalhos de *playtesting* automatizado, incorpora exploração orientada por curiosidade – não para gerar estilos de jogador, mas para que o próprio agente descubra e sinalize regiões do mapa com baixo fluxo de travessia, tratando a detecção de gargalos como o objetivo central da recompensa.

3 Arquitetura do Sistema e Tomada de Decisão

3.1 Representação do Ambiente

Após avaliação da melhor estratégia de *input* para a IA, descartou-se o uso de imagens diretas da câmera (renderização de pixels): o processamento de texturas e iluminação adicionaria um custo computacional desnecessário à rede neural.

A solução estabelecida é a extração estruturada do mapa na forma de uma matriz 2D (*grid*). Utilizando os recursos do Godot 4.7, mapeia-se o `TileMap` e as malhas do `NavigationServer2D` para gerar um *array* bidimensional cujos valores representam os estados do terreno:

- 0: caminho livre e navegável;
- 1: parede ou obstáculo rígido.

Nesta etapa do projeto arquitetural, a geração dessa matriz limpa pelo Godot foi isolada como uma “caixa preta” já funcional, permitindo dedicação integral à modelagem da IA.

3.2 Processamento Espacial com Redes Convolucionais (CNN)

A matriz 2D gerada atua como a observação (*state*) para a rede neural. Para extrair os padrões topológicos desse ambiente espacial — como corredores estreitos, rotas críticas e densidade de obstáculos — os dados passam por uma *Deep Convolutional Network* (CNN). A natureza das CNNs permite que o modelo compreenda o nível de forma geométrica, em vez de apenas ler números isolados, o que é essencial para reconhecer padrões espaciais que caracterizam um gargalo.

3.3 Agente de Deep Reinforcement Learning (DRL)

A tomada de decisão e a exploração do mapa utilizam uma arquitetura de Aprendizado por Reforço Profundo. O modelo é construído com base em conceitos avançados da literatura, unindo *Curiosity-Driven Exploration* com as bases do PCGRL [2]. A Tabela 1 resume os três componentes centrais do sistema.

4 Estado Atual e Trabalhos Futuros

Com a comunicação base e o escopo da IA (matriz 2D → CNN → DRL) validados e definidos, o projeto avança para a estruturação formal do aprendizado de máquina. Os próximos passos incluem:

- (1) **Modelagem matemática da recompensa:** rascunhar a lógica matemática da *reward function*, definindo os pesos de penalização para os gargalos de *level design*;
- (2) **Definição do espaço de ação:** estruturar formalmente quais movimentações e alterações o agente poderá realizar dentro da matriz durante os episódios de treinamento;

Table 1: Componentes do sistema de Aprendizado por Reforço Profundo

Componente	Estratégia no projeto
Observação (<i>State</i>)	A matriz 2D processada pela CNN, representando a topologia instantânea da fase.
Ação (<i>Action</i>)	Navegação vetorial e, posteriormente, a capacidade de sinalizar ou modificar tiles (adicionar/remover bloqueios).
Recompensa (<i>Reward</i>)	O núcleo do sistema: a função matemática penaliza fortemente áreas de baixo fluxo de travessia (gargalos), ensinando o agente a destacar essas falhas no design.

- (3) **Integração de dados:** planejar a exportação contínua da matriz do Godot para o ambiente de treinamento do modelo.

5 Conclusão

Este relatório descreveu a arquitetura em desenvolvimento de um agente de Aprendizado por Reforço Profundo para identificação e correção de gargalos de *level design* em jogos 2D construídos na engine Godot. A representação do ambiente como matriz 2D, processada por uma CNN e consumida por um agente de DRL inspirado em PCGRL e em exploração guiada por curiosidade, oferece um caminho concreto para ir além do *pathfinding* tradicional. Os trabalhos futuros mais imediatos – formalização da função de recompensa, do espaço de ações e da integração de dados – consolidarão a base necessária para os primeiros experimentos de treinamento do agente.

Acknowledgments

Agradecemos ao Prof. Augusto Baffa pela orientação ao longo do desenvolvimento deste projeto, no âmbito da disciplina Projeto Orientado IV (INF1824) da PUC-Rio.

References

- [1] Pierre Le Pelletier De Woillemont, Rémi Labory, and Vincent Corruble. 2022. Automated Play-Testing Through RL Based Human-Like Play-Styles Generation. In *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, Vol. 18.
- [2] Ahmed Khalifa et al. 2020. PCGRL: Procedural Content Generation via Reinforcement Learning. In *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, Vol. 16.
- [3] Alessandro Sestini et al. 2022. Automated Gameplay Testing and Validation with Curiosity-Conditioned Proximal Trajectories. *IEEE Transactions on Games* 16, 1 (2022), 113–126.