

Relatório de Andamento do Projeto

Disciplina: Projeto Orientado IV (INF1824) - PUC-Rio

Aluno: Robert Ronald Calla Maguiña

Orientador: Prof. Augusto Baffa

1. Introdução e Objetivo

Este documento relata o progresso da pesquisa e desenvolvimento da aplicação de Inteligência Artificial para identificação e correção de gargalos de level design. O ambiente de desenvolvimento está sendo estruturado na engine Godot 4.7, com foco no processamento de fases 2D baseadas em física e mecânicas multiplayer.

O objetivo do projeto é ir além da simples navegação (pathfinding). A meta é treinar um agente de aprendizado de máquina capaz de analisar a topologia do mapa, identificar zonas de estrangulamento que prejudicam a fluidez do jogo e aplicar técnicas de geração de conteúdo para sugerir adaptações no cenário.

2. Arquitetura do Sistema e Tomada de Decisão

2.1. Representação do Ambiente

Após avaliação da melhor estratégia de input para a IA, descartou-se o uso de imagens diretas da câmera (renderização de pixels). O processamento de texturas e iluminação adicionaria um custo computacional desnecessário à rede neural.

A solução estabelecida é a extração estruturada do mapa na forma de uma matriz 2D (grid). Utilizando os recursos do Godot 4.7, mapeia-se o TileMap e as malhas do NavigationServer2D para gerar um array bidimensional onde os valores representam os estados do terreno:

- 0: Caminho livre e navegável.
- 1: Parede ou obstáculo rígido.

Nesta etapa de projeto arquitetural, a geração desta matriz limpa pelo Godot foi isolada como uma "caixa preta" já funcional, permitindo dedicação integral à modelagem da IA.

2.2. Processamento Espacial com Redes Convolucionais (CNN)

A matriz 2D gerada atuará como a "observação" (state) para a rede neural. Para extrair os padrões topológicos desse ambiente espacial — como corredores estreitos, rotas críticas e densidade de obstáculos —, os dados passarão por uma Deep Convolutional Network (CNN). A natureza das CNNs permite que o modelo compreenda o nível de forma geométrica, em vez de apenas ler números isolados.

2.3. Agente de Deep Reinforcement Learning (DRL)

A tomada de decisão e a exploração do mapa utilizarão uma arquitetura de Aprendizado por Reforço Profundo. O modelo será construído com base em conceitos avançados da literatura, unindo Curiosity-Driven Exploration com as bases do PCGRL (Procedural Content Generation via Reinforcement Learning).

Componente do Sistema DRL	Estratégia no Projeto
Observação (State)	A matriz 2D processada pela CNN representando a topologia instantânea da fase.
Ação (Action)	Navegação vetorial e, posteriormente, a capacidade de sinalizar ou modificar tiles (adicionar/remover bloqueios).
Recompensa (Reward)	O núcleo do sistema. A função matemática penalizará fortemente áreas de baixo fluxo de travessia (gargalos), ensinando o agente a destacar essas falhas no design.

3. Estado Atual

Com a comunicação base e o escopo da IA (Matriz 2D -> CNN -> DRL) validados e definidos, o projeto avança para a estruturação formal do aprendizado de máquina. Os próximos passos incluem:

1. Modelagem Matemática da Recompensa: Rascunhar a lógica matemática da Reward Function, definindo os pesos de penalização para os gargalos de level design.
2. Definição do Espaço de Ação: Estruturar formalmente quais movimentações e alterações o agente poderá tomar dentro da matriz durante os episódios de treinamento.
3. Integração de Dados: Planejar a exportação contínua da matriz do Godot para o ambiente de treinamento do modelo.

4. Bibliografia

- Khalifa, Ahmed, et al. "Pcgrl: Procedural content generation via reinforcement learning." *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*. Vol. 16. No. 1. 2020.
- De Woillemont, Pierre Le Pelletier, Rémi Labory, and Vincent Corruble. "Automated play-testing through RL based human-like play-styles generation." *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*. Vol. 18. No. 1. 2022.
- Sestini, Alessandro, et al. "Automated gameplay testing and validation with curiosity-conditioned proximal trajectories." *IEEE Transactions on Games* 16.1 (2022): 113-126.